

EP3: Avaliação e Seleção de Modelos de Aprendizado de Máquina

MAC0460/MAC5832 — DCC / IME-USP

Leonardo Heidi Almeida Murakami

NUSP: 11260186

Curso: Bacharelado em Ciência da Computação

1º Semestre de 2026

Resumo

Este relatório apresenta os resultados do EP3. O objetivo foi praticar a avaliação e seleção de modelos usando a biblioteca `scikit-learn` no dataset *Digits*. Testamos os algoritmos SVM, Random Forest, k -NN e Árvore de Decisão. O melhor modelo foi o SVM com kernel RBF, que alcançou 98,15% de acurácia no conjunto de teste.

1 Introdução

O objetivo deste trabalho é aprender a avaliar e escolher modelos de machine learning de forma correta, evitando estimativas erradas de desempenho.

Usamos o dataset *Digits*, que possui 1.797 imagens de dígitos manuscritos (de 0 a 9). Cada imagem tem tamanho 8×8 pixels, gerando 64 atributos (*features*). Avaliamos quatro algoritmos no problema: SVM, Random Forest, k -NN e Árvore de Decisão.

2 Metodologia

O projeto seguiu os seguintes passos:

1. **Visualização:** Plotamos uma amostra das imagens do dataset para entender os dados (Figura 1).
2. **Divisão dos dados:** Separamos o dataset de forma estratificada (mantendo a proporção das classes) em 70% para treino (1.257 amostras) e 30% para teste (540 amostras). O conjunto de teste foi guardado e usado só no final.
3. **Padronização:** Usamos o `StandardScaler` para deixar os atributos na mesma escala (média 0 e variância 1). O ajuste foi feito apenas com os dados de treino.
4. **Modelo Base:** Treinamos um SVM linear padrão ($C = 1.0$) para servir como primeira comparação (Figura 2).
5. **Otimização (Grid Search):** Testamos o SVM com kernel RBF variando os parâmetros C e γ em duas etapas: uma busca grossa (*coarse*) e depois um refino (*fine*).
6. **Comparação de Modelos:** Usamos validação cruzada estratificada com 5 dobras (5-fold CV) para comparar os quatro algoritmos e escolher o melhor com base na acurácia média de validação.




Figura 1: Exemplos de dígitos do dataset Digits.




Figura 2: Matriz de confusão do SVM linear com parâmetros padrão.

3 Resultados

- **SVM Linear Padrão:** Alcançou acurácia de **97,96%** no teste.
- **Grid Search Coarse:** Os melhores parâmetros foram $C = 1.0$ e $\gamma = \text{'scale'}$ (Validação: 98,17%, Teste: 98,33%).
- **Grid Search Fino:** Os parâmetros foram $C \approx 3.16$ e $\gamma = \text{'auto'}$ (Validação: 98,17%, Teste: 98,15%).

A Tabela 1 mostra a comparação final entre todos os algoritmos testados com validação cruzada de 5 dobras. O gráfico correspondente está na Figura 3.

Tabela 1: Comparação de desempenho dos algoritmos.

Algoritmo	Acurácia CV (Média)	Desvio Padrão CV	Acurácia Teste
SVM (RBF)	0,9801	0,0084	0,9815
Random Forest	0,9737	0,0054	0,9667
k -NN	0,9682	0,0056	0,9722
Árvore de Decisão	0,8497	0,0298	0,8574




Figura 3: Acurácia de validação vs. teste por algoritmo.

O melhor modelo final foi o **SVM (RBF)** com $C = 10.0$ e $\gamma = 0.01$. A Tabela 2 traz os detalhes de acertos por classe, e a Figura 4 mostra sua matriz de confusão.

Tabela 2: Relatório de classificação do melhor modelo SVM (RBF).

Classe (Dígito)	Precision	Recall	F1-Score	Support
0	1,00	1,00	1,00	54
1	0,95	0,98	0,96	55
2	1,00	0,98	0,99	53
3	1,00	1,00	1,00	55
4	0,95	0,98	0,96	54
5	1,00	0,98	0,99	55
6	0,98	1,00	0,99	54
7	0,96	1,00	0,98	54
8	1,00	0,92	0,96	52
9	0,98	0,96	0,97	54




Figura 4: Matriz de confusão do melhor modelo SVM RBF.

Separamos na Figura 5 os poucos exemplos que o modelo errou no conjunto de teste.




Figura 5: Exemplos de dígitos classificados incorretamente.

4 Discussão

- **Por que o SVM foi melhor?** O SVM funciona muito bem com muitas dimensões (64 atributos). O uso do kernel RBF permitiu criar regras de separação mais complexas e eficientes do que os outros métodos.
- **Por que a Árvore de Decisão foi pior?** Árvores de decisão sozinhas sofrem muito com *overfitting* (decoreba dos dados de treino). Elas mudam muito com qualquer pequena variação nos dados. O Random Forest corrigiu isso criando várias árvores juntas.
- **Validação Cruzada vs. Teste:** As acurácias de validação e de teste ficaram muito próximas. Isso prova que o processo foi bem feito e que o modelo não sofreu *overfitting* na escolha dos parâmetros. Se usássemos o teste para escolher os parâmetros, o resultado seria mentiroso (viesado).
- **Importância de Padronizar:** O SVM e o k -NN calculam distâncias entre os pontos. Se os pixels não estivessem na mesma escala, os atributos com números maiores iam distorcer todo o cálculo do modelo.

5 Conclusão

O EP3 mostrou a importância de uma metodologia rígida. Separar um conjunto de teste isolado e usar a validação cruzada estratificada em 5 dobras nos deu a certeza de que os resultados são reais e confiáveis. O modelo SVM RBF se mostrou excelente para o reconhecimento dos dígitos manuscritos.

6 Ferramentas de IA utilizadas

Usamos ferramentas de IA de duas formas simples neste trabalho:

- **No código:** Preenchimento automático (*tab completion*) para acelerar a escrita de comandos do scikit-learn e estilização de gráficos.
- **No relatório:** Auxílio para organizar as tabelas e converter o texto resumido para a sintaxe correta do $\text{\LaTeX}$.

Toda a análise dos dados e escolhas de projeto foram feitas pelo próprio aluno.